

HW1 多项式回归与模型选择

机器学习的目标并不仅是在已有数据上获得较小的训练误差，更重要的是从有限样本中学习能够推广到未知数据的规律。随着模型复杂度增加，模型通常能够更充分地拟合训练数据，但其泛化性能并不一定持续提高。因此，如何选择合适的模型复杂度，是监督学习中的基本问题之一。

多项式回归提供了一个简单而直观的实验环境：通过改变多项式阶数，可以连续调整模型的表达能力。本次作业的第一部分将基于一组真实关系未知的观测数据完成多项式回归建模，并使用交叉验证进行模型选择，希望同学们通过实验熟悉数据处理、模型训练、模型选择与最终测试等机器学习的一般流程。

本次作业的第二部分将进一步考察模型复杂度与偏差、方差及预测误差之间的关系。同学们需要在同一数据生成机制下反复获得不同训练样本，比较不同复杂度模型在多次训练中的表现，并在固定评价集上分析偏差、方差和测试误差。希望同学们结合实验现象理解模型复杂度变化带来的影响，并对理论关系与实际实验结果之间可能出现的差异进行分析。

要求：

1. **完成多项式回归模型选择。**请基于第一组数据建立不同阶数的多项式回归模型，候选阶数取 1–8 阶。使用 K 折交叉验证选择合适的模型阶数，并在独立测试数据上完成最终评价。结果中应体现不同模型复杂度下的拟合效果及模型选择过程。
2. **完成偏差—方差实验。**请基于第二组数据选 1 阶、6 阶、8 阶三个多项式模型，在训练样本上重复抽样进行模型训练，比较各模型在多次实验中的预测表现，并结合固定评价集观察不同复杂度模型的稳定性及其与真实响应之间的差异。
3. **比较偏差、方差与预测误差。**在第二部分实验的基础上，计算并比较三个模型对应的偏差、方差和测试误差，分析三者之间的关系。若实验结果与的关系简单的

“误差由偏差平方和方差共同构成”的关系并不完全一致，请结合数据与实验过程进行解释。

注：

1. 本次作业预计提供两组实验数据与 `data` 文件夹中。第一组数据仅包含输入变量与观测响应，用于完成多项式回归与模型选择；第二组数据包含用于重复抽样的训练数据以及一组固定评价数据，用于完成偏差、方差与预测误差实验。`dataset_A_train.csv` 和 `dataset_A_test.csv` 分别用于完成多项式模型选择和评估，`dataset_B_pool.csv` 为重复抽样的训练数据，`dataset_B_evaluation.csv` 为固定评价数据。
2. 作业提交截止时间：9月21日。