

HW2 线性回归

线性回归是监督学习中最基础的模型之一。从建立线性模型、定义损失函数到求解模型参数，线性回归展示了机器学习中模型建立与参数学习的基本过程。对于同一个最小二乘问题，我们既可以利用正规方程求解，也可以通过梯度下降逐步逼近最优解。理解这些方法的数学原理及其在实际计算中的表现，是进一步学习机器学习的重要基础。

本次作业以房源租金预测为背景。第一部分将基于一批房屋条件相近的历史交易数据，建立线性回归模型，分别使用正规方程和梯度下降求解参数，并通过可视化观察模型的学习过程。希望同学们能够将模型的数学表达、参数变化与实际预测结果联系起来，加深对线性回归及其优化方法的理解。

第二部分将进一步提供一批房源类型更加多样化的数据。同学们需要综合运用本章所学知识，建立回归模型，为尚未成交的房源提供租金预测，并结合实际数据完成相应的实验分析。

要求：

1. 完成基础线性回归实验。

请基于第一组数据，以建筑面积和房龄为输入特征、月租金为预测目标，建立线性回归模型，并完成以下实验。

- (1) 分别使用正规方程和自行实现的批量梯度下降求解模型参数，比较两种方法的求解结果。
- (2) 通过可视化展示线性回归模型的学习过程。图像应能够体现样本与拟合结果、模型随迭代的变化、参数更新过程及损失函数的变化，并结合图像解释相关实验现象。
- (3) 自行选择不同的优化设置开展对照实验，分析其对梯度下降求解过程的影响，并结合实验结果说明原因。

2. 完成房源租金预测。

随着业务范围扩大，某租房平台积累了更多不同类型房源的历史交易记录。现提供包含房屋基本信息、地理位置及配套条件等特征的第二组数据。请结合本章所学知识，建立回归模型，并在测试数据上完成租金预测与评价。同时明确给出最终建立的回归模型的数学表达式，提交完整的实验过程、必要的可视化结果及最终预测结果，结合实验结果说明你的建模思路，模型选择依据与结论。

注：

- 1. 本次作业提供两组模拟实验数据。第一组数据包含 1,200 条房源记录，其中训练集 A_train.csv 900 条、测试集 A_test.csv 300 条；第二组包含 9,000 条房源记录，其中训练集 B_train.csv 7,500 条、测试集 B_test.csv 1,500 条。
- 2. 实验报告应包含必要的数学表达、实验过程、结果展示及分析，所有图表应具有清晰的坐标、图例和必要说明，实验结论应有实际结果支持。在实验过程中，可以尝试使用 PCA、t-SNE、UMAP 等降维方法辅助数据可视化，也可以自行选择其他合适的可视化方式，以帮助理解数据及实验结果。
- 4. 提交材料包括实验报告、完整且可复现的程序，报告与程序中的实验设置、结果应保持一致。
- 5. 作业提交截止时间为：10 月 2 日。
- 6. 两个数据具体字段说明如下：**表 1 数据集 A：基础线性回归实验**

字段名称	中文名称	单位或取值	用途
listing_id	房源编号	—	记录标识，不作为预测特征
area_dm2	建筑面积	dm²（平方分米）	自变量
building_age_years	房龄	整数年	自变量
monthly_rent	月租金	元/月	因变量

表 2 数据集 B：房源租金预测

字段名称	中文名称	单位或取值	用途
listing_id	房源编号	—	记录标识，不作为预测特征
area_sqm	建筑面积	m²（平方米）	自变量

字段名称	中文名称	单位或取值	用途
building_age_years	房龄	整数年	自变量
metro_m	距最近地铁站距离	m（米）	自变量
center_km	距市中心距离	km（千米）	自变量
bedrooms	卧室数量	间	自变量
floor	所在楼层	层	自变量
amenities_1km	周边 1 km 内生活设施数量	个	自变量
renovation_score	装修评分	1 - 5 分	自变量
has_elevator	是否配备电梯	0= 否，1=是	自变量
sunlight_hours	日均采光时长	小时	自变量
monthly_rent	月租金	元/月	因变量