HW4 K 近邻算法

K 近邻（K-Nearest Neighbors，KNN）是一类利用样本间相似性进行分类和回归的方法。尽管原理直观，模型的表现仍会受到近邻数量、距离度量、特征尺度及数据维度等因素的影响。本次作业通过模拟实验研究 KNN 的基本性质，并在真实生物数据上开展分类与回归任务。

单细胞 RNA 测序能够同时测量大量基因在不同细胞中的表达，并为细胞类型的识别与比较提供依据，但通常无法保留细胞在组织中的精确位置。空间转录组技术则可将基因表达与细胞的空间坐标联系起来，其中 MERFISH 等成像型技术通常只测量预先选定的一部分基因。将两类数据结合起来，可以利用已有的单细胞参考表达与细胞类型标签开展细胞注释，并预测单细胞或空间数据中未测量的基因表达。相关方法可参考 ENGEP、Emerge 与 scmap 等研究[1–3]。

第一问：模拟数据实验

本题提供两套模拟数据 A 和 B。请利用 KNN 完成以下实验，并结合结果分析模型的特点。

要求：

1. 在数据集 A 上建立 KNN 分类模型，考察近邻数量、距离度量、数据标准化或归一化以及特征维度对分类表现的影响。结合降维方法进行比较，展示实验结果并分析不同方案产生差异的原因。

2. 利用数据集 B 的独立生成程序构造不同训练样本，观察 KNN 分类边界随近邻数量及训练样本变化的情况。绘制分类边界图，并分析边界形状与预测稳定性的关系。

3. 利用数据集 B 开展重复抽样实验，分别对 KNN 的类别概率预测和取 argmax 后的 one-hot 分类标签进行偏差—方差分解。展示偏差、方差和总误差随近邻数量的变化，并比较两种分解结果。

第二问：真实数据实验

本题提供三套具有细胞类型标签的单细胞 RNA 测序参考数据，以及一套具有细胞空间坐标的 MERFISH 数据。请利用 KNN 完成以下任务。

要求：

1. 利用三套单细胞数据中的基因表达与细胞类型标签，开展 KNN 细胞类型注释实验。设计相应的训练与评价方式，比较分类表现，并分析不同数据来源或特征处理方法对结果的影响。

2. 在单细胞数据中选取部分基因作为预测目标，利用其他基因的表达建立 KNN 预测模型。自行选择近邻数量、距离度量、归一化方法及其他合理的模型改进方案，设计验证实验，比较预测效果并解释差异。

3. 以 MERFISH 为预测对象，利用单细胞参考数据和共同测量的基因，预测空间数据中未测量的基因表达。设计能够检验预测能力的实验，展示代表性基因的空间表达结果，并分析预测效果及其局限。

注：

1. 模拟数据：A 为 320 维二分类数据，训练集、验证集和测试集分别含 1,200、300、400 个样本；B 为二维三分类数据，分别含 900、250、400 个样本，另附独立数据生成程序和 600 个固定评估点。

2. 真实数据及文件说明：四套数据均以“细胞 × 基因”保存表达矩阵；矩阵第 i 行与 cells.csv 第 i 行对应，第 j 列与 genes.csv 第 j 行对应。各文件夹内容如下：10X_cells_v2_AIBS（122,641 个细胞、31,053 个基因条目）和 10X_cells_v3_AIBS（71,183 个细胞、31,053 个基因条目）：每个文件夹均含 X_counts.npz（基因表达计数）、cells.csv（细胞 ID、cluster、subclass、class 标签）和 genes.csv（基因 ID、基因名）。SMARTer_cells_MOp（6,288 个细胞、45,768 个基因）：X_exon.npz 为外显子表达计数；cells.csv 为细胞 ID 与细胞类型标签；genes.csv 为基因名称。本题默认采用 exon 计数。MERFISH_mouse2_slice300（3,700 个细胞、254 个基因）：X_expression.npz 为处理后的空间基因表达；cells.csv 为细胞 ID；genes.csv 为基因名称；spatial_coords.csv 为各细胞的 X、Y 空间坐标。根目录的 reference_gene_mapping_253.csv 记录四套数据共有的 253 个基因及其列索引（从 0 开始）。该表仅用于基因对应关系查询，三个单细胞表达矩阵仍保留全部原有基因。三套单细胞参考数据均保留未经归一化的基因表达计数，MERFISH 为经过处理的空间表达数据。

3. 数据探索：可利用 PCA、UMAP 等方法观察细胞表达分布及细胞类型差异，并比较不同数据来源的表达特征。

4. 提交实验报告、完整且可复现的程序，以及 AI 工具使用记录。实验报告与程序中的实验设置、运行结果应保持一致。

5. 作业提交截止时间：11 月 06 日。

参考文献：

[1] Yang, S.-T., Zhang, X.-F. ENGEP: advancing spatial transcriptomics with accurate unmeasured gene expression prediction. Genome Biology, 24, 293 (2023). https://doi.org/10.1186/s13059-023-03139-w

[2] Yang, S.-T., Peng, P., He, H.-F., et al. Microenvironment-aware transcriptome reconstruction in spatial transcriptomics. Nature Communications, 17, 10514 (2026). https://doi.org/10.1038/s41467-026-77349-8

[3] Kiselev, V. Y., Yiu, A., Hemberg, M. scmap: projection of single-cell RNA-seq data across data sets. Nature Methods, 15, 359–362 (2018). https://doi.org/10.1038/nmeth.4644